AI画像読み取り・トリミング検証結果

小学校算数テスト画像を対象としたPoC - Stage A / Stage B / 単元推定 / AI接続方法

今回の更新点：Stage Bの3ケースが「実答案の誤り」ではなく想定ケースであることを明記。単元名欠落時の推定検証を追加し、PoCでAIへどのように接続したかも追記した。

1. Stage A / Stage Bとは？

工程	役割	推測の扱い
Stage A	画像から問題文・子どもの回答・途中式・採点など、見えている事実を抽出	画像にない情報を推測しない
保護者確認	Stage Aの読み取り結果を確認し、誤りがあれば修正	確認済みデータを作る
Stage B	確認済みデータから推定単元・間違え方パターン等を分析	根拠が弱い場合は「判定困難」



MVP方針： Stage A / Stage BともにGemma 4 26B A4Bを利用する。単元推定はStage AではなくStage Bで行う。

2. Visionモデル比較（Stage A）

実際の小3算数テスト画像3枚を使い、同じ目的のプロンプト・専用OCRなしでGemma 4 26B A4BとGPT-5 Nanoを比較した。今回の条件ではGemmaは3/3枚、GPT-5 Nanoは1/3枚で内容を抽出した。これは今回の検証条件における結果であり、モデル一般の優劣を示すものではない。

観点	確認結果
Gemma	3枚すべてで内容抽出。手書き・途中式・採点も比較的多く取得
GPT-5 Nano	3枚中1枚で内容抽出
残った課題	Gemmaでも小数点などの視覚的な誤読が残った

3. Stage Aプロンプトで重視したこと

「読める事実だけ」「問題を解かない」「推測・補完しない」「印刷問題・児童の手書き・途中式・先生の赤字を分ける」「読めない場合は不明とする」という制約を入れた。プロンプト強化で推測は抑えられたが、視覚的な誤読そのものは完全には防げなかった。

> そのため、AI出力を自動確定せず、保護者による確認・修正をMVP必須要件とする。

4. トリミング検証

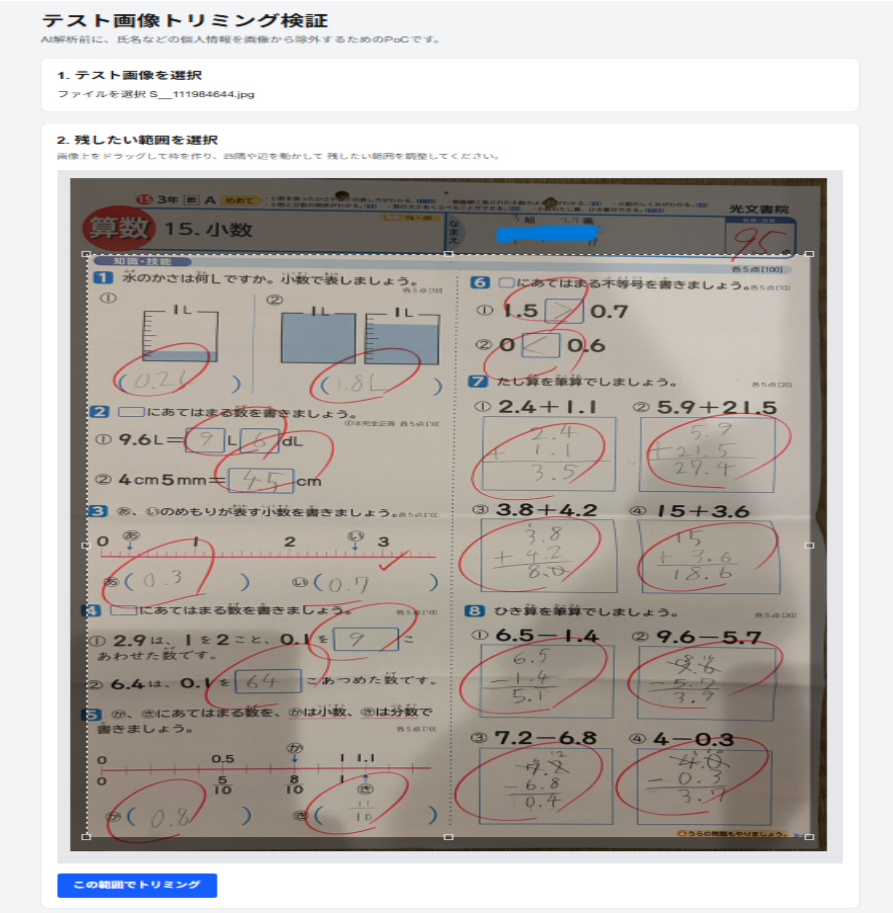
氏名などの個人情報を外部AIへ送る前に除外できるよう、ブラウザ上で自由矩形トリミングを行うPoCを作成した。固定比率ではなく、必要な部分だけを除外できる自由矩形方式を採用する。



図：ブラウザ上で残したい範囲を選択するトリミングPoC。個人情報部分はマスクして掲載。

5. トリミング後の読み取り結果

T03では、氏名等のヘッダー部分だけを除外した画像をGemmaのStage Aへ入力した。今回の1画像では大きな読み取り低下は確認されず、既存の「4.5cm→45」の誤読は残った。



一方、問題部分まで意図的に切りすぎた検証では、完全に欠落した問題を復元する挙動は確認されなかったが、問題番号・見出しの欠落により残存問題の番号を誤認した。

> UI案内：「氏名など不要な部分だけを除外し、問題番号・問題文・回答・採点はできるだけ残してください。単元名が含まれている場合は、可能な範囲で残してください。」

6. Stage B（間違え方パターン分析）の簡易検証

検証方法
ここで使った3ケースは、実際の答案にその誤りがあったことを示すものではない。Stage Bの分類能力を確認するために、異なる誤答パターンを想定して作成した検証用データである。画像は直接渡さず、Stage A後に保護者が確認・修正した「確認済みデータ」を想定したテキストだけを入力した。

Case	想定した誤答パターン	Gemmaの結果	評価
1	小数：正答4.5cmに対して45cmと回答したと想定	小数点の位置の誤り／原因：判定困難	○
2	わり算：回答が空欄だったと想定	パターン：判定困難／原因：空欄	○
3	筆算：繰り上がりを次の位に加えなかったと想定	計算手順の誤り／原因：判定困難	○

分析精度について

今回の3ケースでは、3/3ケースで事前に想定した分類方針に沿う出力を確認した。特に、根拠不足時に「ケアレスミス」「理解不足」と断定せず「判定困難」とする挙動を確認できた。ただし、3ケースのみの初期検証であり、「分析精度100%」を意味しない。実装後もケース数を増やして継続検証する。

7. 単元名がトリミングで欠落した場合の推定検証

単元名を入力せず、問題内容・子どもの回答・正答・途中式などの確認済みデータだけから、Gemmaが単元を推定できるかを3ケースで確認した。

Case	問題内容	Gemmaの推定	確実性	評価
1	4cm5mmをcmで表す	長さ（小数の表し方）	高	○
2	24個を6人に等分	わり算	高	○
3	368+457の筆算	三桁の数のたし算	高	○

今回の3ケースでは3/3ケースで想定した単元に沿う推定結果が得られた。ただし、全単元・全問題形式での精度を示すものではない。

MVPへの落とし込み

単元名がStage Aで取得できた場合はその情報を利用する。単元名がトリミング等で取得できない場合は、保護者確認後のStage Bで問題内容から「推定単元」を出す。判断できない場合は「判定困難」とする。単元推定専用の画面やAPIを増やすのではなく、Stage Bの出力項目として組み込む。



8. どんなふうにAIに接続して検証したの？

検証は、WSL（Ubuntu）上で作成したPythonスクリプトからAI APIへリクエストを送る方法で行った。ブラウザのチャット画面に手作業で入力して比較したのではなく、同じ形式の入力をコードから送り、返ってきた結果をファイルに保存して比較できるようにした。



検証	AIへ送ったもの	確認したこと
Stage A	テスト画像＋Stage Aプロンプト	画像から見えている事実をどこまで抽出できるか
Stage B	想定ケースの確認済みテキスト＋Stage Bプロンプト	間違え方を安全に分類できるか
単元推定	単元名を除いた確認済みテキスト＋単元推定プロンプト	問題内容だけから単元を推定できるか

今回のGemma Stage B・単元推定PoC： Google Generative Language APIへ検証用APIキーで直接接続し、gemma-4-26b-a4b-itを呼び出した。APIキーは環境変数で管理し、資料には記載しない。

PoCとMVPの接続経路の違い

MVPでは Next.js / FastAPI → OpenRouter（ZDR対応Endpoint）→ Gemma の構成を予定している。今回の直接API接続はモデル挙動を短時間で確認するPoC用であり、MVPの実際の接続経路とは異なる。そのため、実装時にはOpenRouter経由でも代表ケースを再実行し、挙動差がないか確認する。

重要：「同じGemmaを使う」ことと「接続経路が同じ」ことは別。PoCの結果をそのままOpenRouter経由の動作保証とはせず、MVP経路で再確認する。

9. MVPでの最終処理フローと検証上の注意



Stage Bでは、必要に応じた単元推定、間違え方パターン、原因分類、判断理由などを生成し、結果画面へつなげる。単元推定は「単元名が欠落しても解析を継続しやすくする補助」であり、Stage Aの推測禁止ルールは維持する。

項目	現時点の評価
Stage A	実画像3枚で比較済み。GemmaをMVP候補として採用。ただし視覚誤読あり
トリミング	個人情報部分だけの除外は今回の1画像で大きな低下なし。過剰トリミングは構造認識を損なう
Stage B分類	想定3ケースで3/3が期待方針に沿った。全体精度を測ったものではない
単元推定	単元名なし3ケースで3/3が想定単元に沿った。全単元の精度保証ではない
接続	PoCの直接API接続とMVPのOpenRouter経由は異なるため、MVP経路で再テストする

次の検証： OpenRouter経由で代表ケースを再実行／実アプリで処理時間を計測／実装後にStage B・単元推定のケース数を増やす。